


Text clustering và Topic modelling



Classification vs Clustering

Classification

- Có nhãn huấn luyện: spam/không spam, positive/negative.
- Mục tiêu: học ranh giới để dự đoán nhãn cho mẫu mới.
- Đánh giá bằng accuracy, precision, recall, F1.
- Cần dữ liệu đã được gán nhãn.

Clustering

- Không có nhãn ban đầu.
- Mục tiêu: nhóm tài liệu tương tự vào cùng cụm.
- Đánh giá bằng silhouette, DB index hoặc nhãn tham chiếu nếu có.
- Dùng để khám phá cấu trúc dữ liệu.

Document clustering vs Topic modelling

Document clustering

Doc A → Cụm 1

Doc B → Cụm 2

Doc C → Cụm 1

Câu hỏi: “tài liệu này giống nhóm nào nhất?”

Tổ chức kho tài liệu

Gom tài liệu tương tự để duyệt nhanh.

Phân tích tin tức

Nhóm tin theo sự kiện/chủ đề.

Phản hồi khách hàng

Khám phá nhóm phản nản hoặc nhu cầu mới.

Hỗ trợ gán nhãn

Chọn mẫu tiêu biểu để annotate.

Topic modelling

Doc A = 70% thể thao + 20% kinh tế + 10% xã hội

Doc B = 60% giáo dục + 40% công nghệ

Câu hỏi: “tài liệu này thuộc những chủ đề nào?”

Phát hiện chủ đề mới

Theo dõi xu hướng tăng nhanh.

Biểu diễn văn bản và độ tương tự


Count

TF-IDF

Embedding

Similarity

Từ văn bản thành vector



Cách biểu diễn quyết định “tài liệu nào được xem là gần nhau”.

Cùng một thuật toán clustering có thể cho kết quả rất khác nếu đổi TF-IDF sang sentence embedding.

```
docs = [  
    "pin rất tốt, giao hàng nhanh",  
    "màn hình đẹp nhưng pin yếu",  
    "ship chậm, đóng gói kém"  
]
```

```
X = vectorizer.fit_transform(docs)  
labels = model.fit_predict(X)
```

Count vector

Count vector biểu diễn mỗi tài liệu bằng số lần xuất hiện của từng từ trong tập từ vựng.

Doc	pin	tốt	giao_hàng	chậm
D1: pin tốt	1	1	0	0
D2: giao_hàng chậm	0	0	1	1
D3: pin chậm	1	0	0	1

Ưu điểm: đơn giản, dễ giải thích.

Hạn chế: bỏ qua thứ tự từ, ngữ nghĩa và dễ bị ảnh hưởng bởi từ phổ biến.

TF-IDF: giảm vai trò của từ quá phổ biến

$$\text{tfidf}(t,d) = \text{tf}(t,d) \times \text{idf}(t)$$

$\text{tf}(t,d)$: tần suất từ t trong tài liệu d

$\text{idf}(t)$: mức độ hiếm của từ t trong toàn bộ corpus

$$\text{idf}(t) = \log(N / \text{df}(t))$$

N : số tài liệu

$\text{df}(t)$: số tài liệu chứa từ t

Từ càng xuất hiện ở nhiều tài liệu thì idf càng thấp.

Ví dụ

Trong phản hồi sản phẩm, các từ “sản phẩm”, “mình”, “rất” xuất hiện nhiều → ít phân biệt.

Các từ “pin”, “màn_hình”, “ship”, “bảo_hành” thường hữu ích hơn cho clustering/topic.

Embedding: từ “đếm từ” sang “ngữ nghĩa”

Word embedding

Mỗi từ có một vector.

Ví dụ: “giá”, “chi_phí”, “đắt” có thể gần nhau trong không gian vector.

Document embedding

Biểu diễn cả tài liệu bằng một vector. Có thể trung bình word vectors hoặc học trực tiếp.

Sentence embedding

Biểu diễn câu/đoạn ngắn theo ngữ nghĩa. Phù hợp với phản hồi khách hàng ngắn.

Ví dụ: “pin trâu” và “thời lượng dùng lâu” không giống nhau về từ vựng nhưng có thể gần nhau trong embedding space.

Euclidean distance và Cosine similarity

$$d(x,y) = \sqrt{\sum_i (x_i - y_i)^2}$$

Euclidean distance đo khoảng cách tuyệt đối giữa hai vector. Nhạy với độ dài vector.

$$\cos(x,y) = (x \cdot y) / (\|x\| \|y\|)$$

Cosine similarity đo hướng của vector. Phổ biến với TF-IDF và dữ liệu văn bản thưa.

Nhận xét:

Hai tài liệu cùng chủ đề nhưng khác nhau độ dài vẫn có cosine cao.

Với văn bản, cosine thường phù hợp hơn khi độ dài tài liệu khác nhau.

Ảnh hưởng của chuẩn hóa vector

- Nếu vector chưa chuẩn hóa, tài liệu dài có thể có norm lớn hơn và chi phối khoảng cách.
- L2-normalization đưa vector về cùng độ dài: $\|x\|_2 = 1$.
- Khi vector đã L2-normalized thì Euclidean distance và cosine có quan hệ gần nhau.
- Chuẩn hóa đặc biệt quan trọng với TF-IDF + K-means.

$$x_{\text{norm}} = x / \|x\|_2$$

Sau chuẩn hóa, mô hình tập trung hơn vào phân bố từ/chủ đề thay vì độ dài tài liệu.

Curse of dimensionality và giảm chiều

Curse of dimensionality

Là hiện tượng khi số chiều của không gian biểu diễn tăng cao, dữ liệu trở nên thừa và các phép đo khoảng cách/độ tương tự trở nên kém phân biệt dẫn đến giảm hiệu quả của nhiều thuật toán học máy.

VD: Vocabulary: 50.000 từ. Document: chỉ chứa 100 từ khác nhau

→ vector biểu diễn tài liệu là vector cực kỳ thừa. Khi số chiều tăng cao, các điểm dữ liệu có xu hướng trở nên xa nhau dẫn đến khoảng cách giữa “điểm gần” và “điểm xa” có thể không còn khác biệt rõ

→ gây khó khăn cho Kmeans, KNN, DBSCAN, HA

Giảm chiều

Mục tiêu: giữ cấu trúc quan trọng trong ít chiều hơn để phân cụm, trực quan hóa, giảm nhiễu.

Không phải lúc nào giảm chiều cũng cải thiện kết quả.

PCA, Truncated SVD và UMAP

Phương pháp	Ý tưởng	Khi dùng
PCA	Tìm các hướng phương sai lớn nhất.	Dữ liệu dense, trực quan hóa cơ bản.
Truncated SVD	Xấp xỉ ma trận thưa bằng số chiều thấp.	TF-IDF nền tảng của LSA.
UMAP	Giữ cấu trúc lân cận phi tuyến.	Trực quan hóa embedding - BERTopic.

Text clustering

Quy trình



- Kết quả clustering không tự có tên nhãn mà người phân tích phải diễn giải cụm.
- Cần kiểm tra nhiều K, nhiều seed và nhiều kiểu biểu diễn.
- Cụm tốt về metric chưa chắc dễ diễn giải.

K-means

Input

Tập vector tài liệu
 $X = \{x_1, x_2, \dots, x_n\}$
Số cụm K

Lặp

1. Gán mỗi điểm vào centroid gần nhất.
2. Cập nhật centroid bằng trung bình các điểm trong cụm.

Output

Nhãn cụm cho mỗi tài liệu.
Centroid đại diện cho mỗi cụm.

Khởi tạo centroid



Gán cụm



Cập nhật centroid



Hội tụ

Chọn số cụm K

- Không có K “đúng tuyệt đối” trong học không giám sát.
- Elbow method: xem điểm gãy của inertia/SSE khi tăng K.
- Silhouette: chọn K có mức tách cụm và độ chặt cụm tốt.
- Khả năng diễn giải: cụm có tên rõ, tài liệu tiêu biểu nhất quán.
- Ổn định: chạy lại với nhiều seed vẫn ra cấu trúc tương tự.

Hierarchical & Agglomerative clustering

Hierarchical clustering

Tạo cấu trúc phân cấp các cụm.
Có thể xem bằng dendrogram.

Agglomerative

Bắt đầu từ mỗi tài liệu là một cụm, rồi gộp dần các cụm gần nhau.

Linkage

single, complete, average, ward.
Mỗi cách đo khoảng cách giữa hai cụm khác nhau.

Doc riêng lẻ



Gộp gần nhất



Cụm lớn dần



Dendrogram

DBSCAN và HDBSCAN

DBSCAN

- Dựa trên mật độ điểm.
- Không cần chọn số cụm K.
- Có thể phát hiện noise/outlier.
- Nhạy với eps và min_samples.

HDBSCAN

- Mở rộng ý tưởng mật độ theo nhiều thang mật độ.
- Phù hợp khi cụm có mật độ khác nhau.
- Thường dùng trong BERTopic.
- Có thể tạo nhãn -1 cho tài liệu nhiễu.

Đặt tên và diễn giải cụm

- Xem các tài liệu gần centroid nhất hoặc tài liệu tiêu biểu nhất.
- Lấy top terms theo TF-IDF trung bình trong cụm.
- So sánh cụm với các cụm khác để tìm từ phân biệt.
- Đặt tên cụm bằng mô tả ngắn gọn.
- Luôn kiểm tra một số tài liệu bị gán sai hoặc nằm gần ranh giới cụm.

Đánh giá nội tại: Silhouette score

$$s(i) = (b(i) - a(i)) / \max(a(i), b(i))$$

$a(i)$: khoảng cách trung bình từ i đến các điểm cùng cụm

$b(i)$: khoảng cách trung bình nhỏ nhất từ i đến cụm khác gần nhất

Diễn giải

s gần 1: điểm nằm tốt trong cụm của nó.

s gần 0: điểm nằm gần ranh giới.

s âm: điểm có thể bị gán sai cụm.

Đánh giá nội tại: Davies–Bouldin index

$$DB = (1/K) \sum_i \max_{j \neq i} (S_i + S_j) / M_{ij}$$

S_i : độ phân tán trong cụm i

M_{ij} : khoảng cách giữa centroid cụm i và j

Giá trị càng thấp thường càng tốt.

- Ưu điểm: không cần nhãn tham chiếu.
- Dùng để so sánh nhiều cấu hình clustering.
- Hạn chế: cụm “đẹp” về hình học chưa chắc có ý nghĩa ngữ nghĩa.
- Nên đi kèm phân tích top terms và tài liệu tiêu biểu.

Đánh giá khi có nhãn tham chiếu: ARI và NMI

Adjusted Rand Index (ARI)

- So sánh mức độ đồng thuận giữa clustering và nhãn thật theo cặp mẫu.
- Có điều chỉnh yếu tố ngẫu nhiên.
- 1: khớp hoàn hảo, gần 0: tương đương ngẫu nhiên.

Normalized Mutual Information (NMI)

- Dựa trên lượng thông tin chung giữa nhãn cụm và nhãn thật.
- Chuẩn hóa để nằm trong khoảng dễ so sánh.
- Ít phụ thuộc trực tiếp vào tên nhãn.

Phân tích tính ổn định của cụm

- Chạy clustering với nhiều random seed khác nhau.
- Thay đổi nhẹ preprocessing, min_df, max_df, ngram_range.
- Thử các biểu diễn khác nhau: TF-IDF, SVD, sentence embedding.
- So sánh bằng ARI giữa các lần chạy hoặc kiểm tra top terms/tài liệu tiêu biểu.
- Cụm không ổn định thường không nên dùng để đưa ra kết luận chắc chắn.

Topic modelling

Tìm các chủ đề ẩn và cách chúng phân bố trong tài liệu.

LSA/SVD

NMF

LDA

BERTopic

Topic modelling là gì?

Topic modelling tìm các chủ đề ẩn trong tập tài liệu và biểu diễn tài liệu bằng phân phối trên các chủ đề.

Topic

Một phân phối trên từ.

Ví dụ: topic “giao hàng” có top words: ship, giao_hàng, chậm, đóng_gói.

Document

Một hỗn hợp nhiều topic.

Ví dụ: 60% giao hàng + 30% chất lượng + 10% giá.

Topic model không bắt buộc mỗi tài liệu chỉ thuộc một nhóm duy nhất.

Latent Semantic Analysis (LSA) và Truncated SVD

Ý tưởng

Từ xuất hiện trong ngữ cảnh tương tự sẽ được đưa gần nhau trong không gian thấp chiều.

LSA hữu ích để giảm nhiễu và phát hiện cấu trúc chủ đề thô.

$$X \approx U_k \Sigma_k V_k^T$$

X: ma trận document-term

SVD xấp xỉ X bằng k chiều ẩn

Các chiều ẩn có thể diễn giải như chủ đề tiềm ẩn.

Non-negative Matrix Factorization (NMF)

$$X \approx W H, \text{ với } W \geq 0, H \geq 0$$

X: ma trận document-term

W: document-topic

H: topic-word

Không âm giúp topic dễ diễn giải hơn.

Ví dụ topic từ H

Topic 1: ship, giao_hàng, chậm, đóng_gói

Topic 2: pin, sạc, thời_lượng, nóng

Topic 3: bảo_hành, đổi_trả, lỗi, hỗ_trợ

NMF thường hoạt động tốt với TF-IDF và cho top words dễ diễn giải.

Latent Dirichlet Allocation (LDA)

LDA là mô hình xác suất sinh phân cấp: tài liệu sinh ra bằng cách chọn topic, rồi chọn từ từ topic đó.



Document–topic distribution θ_d

Ví dụ: tài liệu d = 50% giao_hàng + 35% pin + 15% giá.

Topic–word distribution φ_k

Ví dụ: topic giao_hàng ưu tiên các từ ship, chậm, đóng_gói, giao_hàng.

LDA: công thức sinh ở mức khái niệm

$$\theta_d \sim \text{Dirichlet}(\alpha)$$

Mỗi tài liệu có phân phối trên topic.

α nhỏ thì tài liệu thường tập trung vào ít topic.

$$\phi_k \sim \text{Dirichlet}(\beta)$$

Mỗi topic có phân phối trên từ.

β nhỏ thì topic tập trung vào ít từ đặc trưng.

$$z_{\{d,n\}} \sim \text{Categorical}(\theta_d)$$

$$w_{\{d,n\}} \sim \text{Categorical}(\phi_{\{z_{\{d,n\}}\}})$$

Với mỗi vị trí từ n trong tài liệu d : chọn topic z , sau đó chọn từ w từ topic đó.

LDA

- Bag-of-words: bỏ qua thứ tự từ, chỉ xét số lần xuất hiện.
- Tài liệu là hỗn hợp nhiều topic và topic là phân phối trên từ.
- Tham số Dirichlet điều khiển độ “thừa” của phân phối.
- Từ các từ quan sát được, ước lượng topic của từng từ và phân phối topic của tài liệu.
- Các thuật toán thường gặp: Gibbs sampling, variational inference.

Chọn số lượng topic và đánh giá topic

Metric	Ý nghĩa	Lưu ý
Topic coherence	Top words trong topic có liên quan ngữ nghĩa không?	Gần với đánh giá của con người hơn perplexity.
Perplexity	Mức độ mô hình dự đoán dữ liệu held-out tốt không?	Thấp hơn tốt hơn, nhưng không luôn tương quan với diễn giải.
Topic diversity	Các topic có trùng top words quá nhiều không?	Cao hơn giúp topic ít lặp nhau.
Manual evaluation	Con người có đặt tên và hiểu topic được không?	Bắt buộc khi dùng cho phân tích thực tế.

Dynamic topic và hierarchical topic

Dynamic topic

- Theo dõi chủ đề thay đổi theo thời gian.
- Ví dụ: tin tức về “AI” trước/sau khi có một sự kiện lớn.
- Hữu ích cho phân tích xu hướng và truyền thông.

Hierarchical topic

- Tổ chức topic theo cây cha–con.
- Ví dụ: “công nghệ” → “AI”, “thiết bị”, “bảo mật”.
- Hữu ích khi corpus lớn và nhiều mức khái quát.

BERTopic: embedding + clustering + c-TF-IDF



Ý tưởng chính

BERTopic không bắt đầu từ count matrix như LDA mà dùng embedding để nhóm tài liệu theo ngữ nghĩa, sau đó dùng c-TF-IDF để tìm từ đại diện cho từng cụm/topic.

Ưu điểm: mạnh với văn bản ngắn, topic theo ngữ nghĩa.

Hạn chế: phụ thuộc embedding, UMAP/HDBSCAN và tham số.

Class-based TF-IDF trong BERTopic

Khác TF-IDF truyền thống: đơn vị “document” ở đây là toàn bộ cụm thay vì từng tài liệu riêng lẻ.

Mục tiêu

Tìm các từ phân biệt cụm này với các cụm khác.

Ví dụ cụm “giao hàng”: ship, chậm, đóng_gói, giao_hàng, nhận_hàng.

$$\text{c-TF-IDF}(t,c) = \text{tf}(t,c) \times \log(A / \text{df}(t))$$

c : một cụm/topic được xem như một “document lớn”

$\text{tf}(t,c)$: tần suất từ t trong cụm c

A : độ dài trung bình của các cụm

$\text{df}(t)$: số cụm chứa từ t

Thực hành

- Dữ liệu: tin tức hoặc phản hồi khách hàng tiếng Việt.
- So sánh 5 hệ thống: TF-IDF + K-means, NMF, LDA, sentence embedding + K-means, BERTopic.
- Cố định tập dữ liệu và preprocessing để so sánh công bằng.
- Xuất biểu diễn 2D của tài liệu bằng PCA/SVD/UMAP.
- Ghi lại top words, tên topic thủ công và tài liệu tiêu biểu.

Bài nộp

Biểu diễn 2D

Scatter plot tài liệu, tô màu theo cụm/topic.

Top keywords

Từ khóa đại diện cho từng cụm/topic.

Tên topic

Đặt tên thủ công và giải thích cơ sở.

Metric

Coherence hoặc silhouette, có so sánh giữa mô hình.

Error analysis

Tài liệu gán sai, topic khó diễn giải, topic trùng nhau.

Tóm tắt chương

Ý chính	Cần nhớ
Clustering	Gom tài liệu tương tự; thường mỗi tài liệu có một cụm chính.
Topic modelling	Tài liệu là hỗn hợp nhiều chủ đề; topic là phân phối trên từ.
Biểu diễn	TF-IDF dễ giải thích; embedding nắm tốt hơn ngữ nghĩa.
Đánh giá	Metric chỉ là một phần; phải phân tích top terms và tài liệu tiêu biểu.
Thực hành	So sánh nhiều pipeline trên cùng dữ liệu, ghi nhận lỗi và tính ổn định.

Câu hỏi ôn tập

- Vì sao cosine similarity thường phù hợp với TF-IDF hơn Euclidean distance thô?
- Khi nào clustering phù hợp hơn classification?
- Vì sao LDA xem tài liệu là hỗn hợp nhiều chủ đề?
- So sánh NMF và LDA theo khả năng diễn giải topic.
- BERTopic khác LDA ở pipeline và giả định nền tảng như thế nào?
- Nếu silhouette cao nhưng topic khó đặt tên, bạn xử lý ra sao?